

Semana 19

Redes Neuronales Convolucionales

Ciencia de Datos e Inteligencia Artificial

Lifelong Learning UDD
El valor de la formación sin límites

6 UNIVERSIDAD DEL DESARROLLO
UNIVERSIDAD DEL DESARROLLO
UNIVERSIDAD DEL DESARROLLO
UNIVERSIDAD DEL DESARROLLO

Powered by
scala
LEARNING

MOMENTOS

IMPORTAN
TES


Ciencia de Datos y AI



Tiempo de
participemos



Iniciamos
y finalizamos
a tiempo



Escuchemos
opiniones,
micrófonos en off



Mantengamos
nuestra cámara
encendida



Ponte a
prueba



MÓDULO 4

Introducción

MÓDULO 5

ML: Modelado supervisado

MÓDULO 6

Procesamiento de lenguaje natural

16

SEMANA

17

SEMANA

18

SEMANA

19

SEMANA

20

SEMANA

21

SEMANA

22

SEMANA

23

SEMANA

24

SEMANA



Presentación
de proyecto



Presentación
de proyecto

Agenda

del
día

Ciencia de Datos y AI



Daily

Dudas y progreso de la semana

Redes neuronales convolucionales

Computer Vision

Creando imágenes con Inteligencia Artificial

Break

20 minutos de descanso

Entorno de ejecución

Análisis de código

Próximos pasos

Dudas y cierre



Daily

Pongámonos al día



Las **redes neuronales convolucionales**, regularmente abreviadas como **CNN** por las siglas del inglés, *Convolutional Neural Networks*, es una red de neuronas que tratan de asimilar el comportamiento de la visión humana. Al hablar de esto no sólo hacemos mención a la función de los ojos, sino también de nuestro cerebro, específicamente la corteza frontal, de cómo funciona la información que recibimos a través de nuestros ojos.



Es un perro

No es un perro



Computer vision



Filtros y auto enfoque de fotografías




Detección de rostros



Computer vision en las noticias



Creando imágenes con Inteligencia Artificial



AI won an art contest, and artists are furious



Generadores de imágenes



<https://www.craiyon.com/>

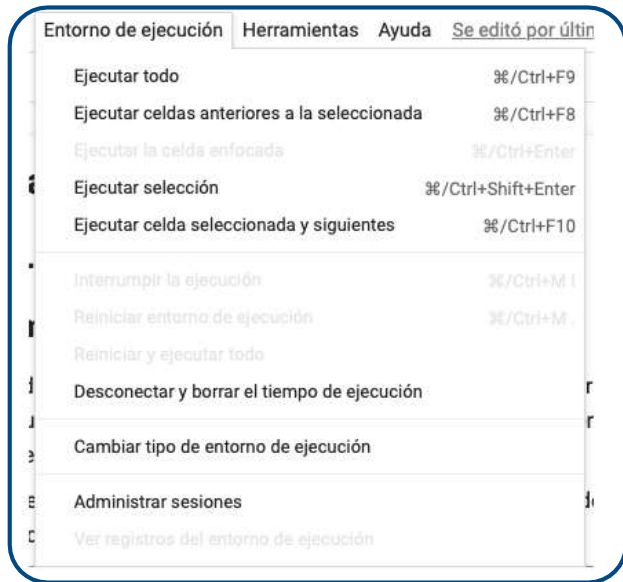
Página para imágenes generadas por inteligencia artificial

Entorno de ejecución



El uso de redes neuronales tiene dos inconvenientes mayores:

- Las capas ocultas son como «cajas oscuras».
- Se requiere mucha memoria de procesamiento





En Google Colaboratory es posible indicar que queremos usar GPU para optimizar nuestros modelos CNN.

Si usas una herramienta en entorno virtual, requerirás mayor memoria de procesamiento, por lo anterior, valida si el uso de redes neuronales es lo más óptimo para resolver un problema.

Configuración del notebook

Acelerador de hardware

GPU ?

Want access to premium GPUs?
[Purchase additional compute units here.](#)

☐ Omitir el resultado de las celdas al guardar este notebook

Cancelar Guardar

Redes Neuronales Convolucionales (CNN)



El documento "Gradient-Based Learning Applied to Document Recognition" de LeCun et al. es un trabajo fundamental en el campo del aprendizaje automático, específicamente en el desarrollo y aplicación de Redes Neuronales Convolucionales (CNN). Las CNN son un tipo de red neuronal profunda que se utiliza ampliamente para tareas de procesamiento de imágenes y reconocimiento de patrones. Este tipo de redes se caracteriza por su capacidad para aprender jerarquías de características de manera automática, desde características de bajo nivel hasta características más abstractas. Las CNN son particularmente efectivas en la detección de patrones visuales en imágenes, lo que las hace ideales para aplicaciones como el reconocimiento de documentos, el procesamiento de imágenes médicas y la visión por computadora. Este documento es reconocido por su contribución significativa al avance de las CNN y su aplicación en el reconocimiento de documentos.

Arquitectura CNN (LeNet-5)



PROC. OF THE IEEE, NOVEMBER 1998

7




Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

Input (Entrada)



INPUT
32x32




- Es donde se alimenta la imagen en la red. En el caso de LeNet, el tamaño de la entrada es de 32x32 píxeles.
- Cada píxel contiene información sobre la intensidad (por ejemplo, tonos de gris en una imagen en escala de grises).



Ejemplo de imágenes
de entrada del dataset
MNIST

Convoluciones



- Este paso aplica filtros (kernels) sobre la imagen para extraer características importantes como bordes, texturas, y patrones.
- Cada filtro se mueve por la imagen, y genera un mapa de características (feature map).
- Ejemplo: Si la entrada tiene un tamaño 32x32 y aplicamos 6 filtros, obtendremos 6 mapas de características.
- El objetivo principal es detectar características básicas en la imagen


Submuestreo (Pooling o

- En LeNet, se usa submuestreo promedio (average pooling) o máximo (max pooling) para reducir el tamaño de los mapas de características.


- Por ejemplo, si un mapa de características tiene dimensiones de 28×28 , después del pooling puede reducirse a 14×14 .

- Max pooling selecciona el valor máximo en una región, mientras que average pooling calcula el promedio.

- El objetivo es retener las características mas importantes



Capas Completamente Conectadas (Fully Connected Layers)




- Una vez que los mapas de características son suficientemente pequeños, se "aplanan" en un vector.
- Este vector pasa por capas completamente conectadas, donde cada neurona está conectada con todas las neuronas de la capa anterior.
- En esta etapa, el modelo aprende combinaciones de características para clasificar la imagen.



Modelos Pre Entrenados


VGG (Visual Geometry Group)



Ideal para imágenes en color, como fotos de objetos, animales y escenas naturales y es compatible con torchvision y tensorflow.keras.applications

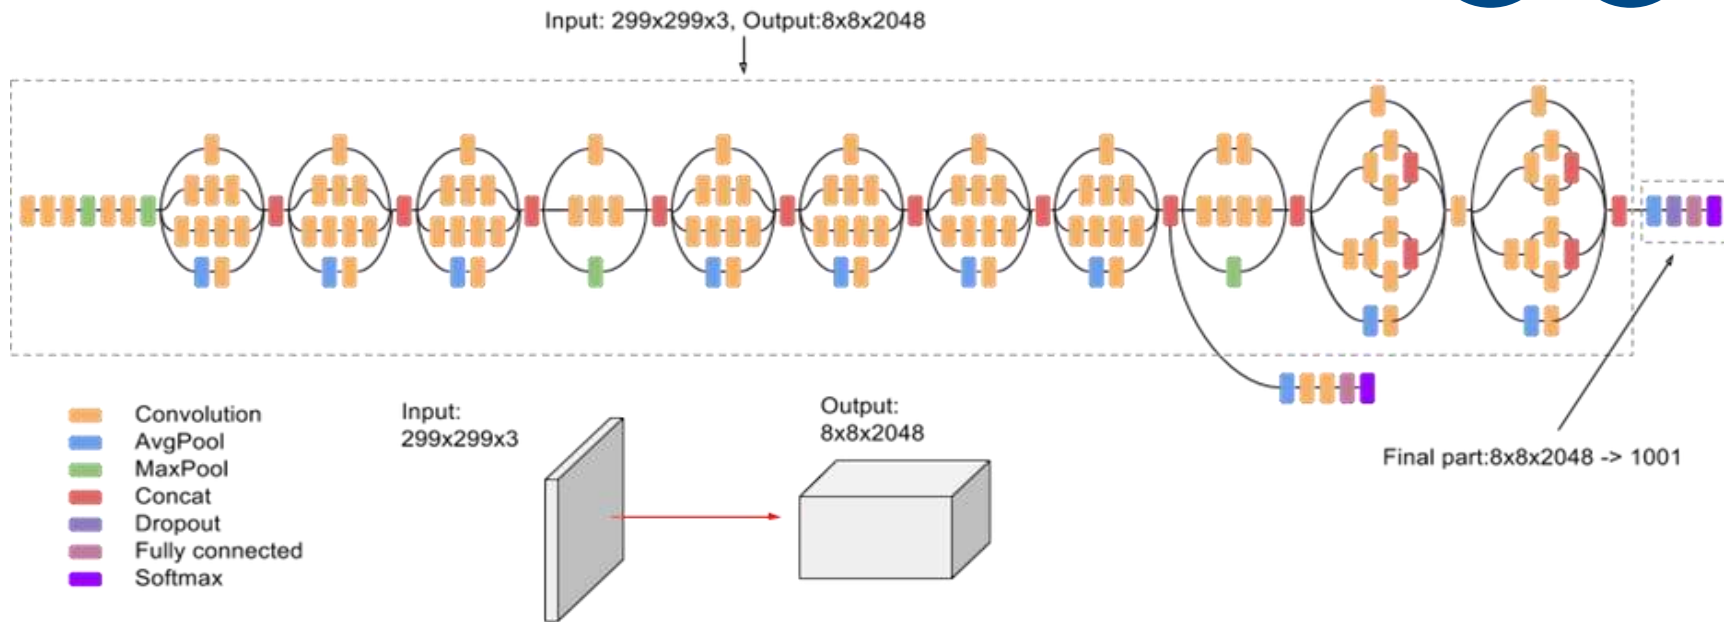
https://www.researchgate.net/figure/Architecture-of-the-modified-VGG16-model_fig1_350828239

ResNet (Residual Network)



Perfecto para imágenes complejas como las médicas, de satélite o con muchos detalles y es compatible con torchvision (resnet18, resnet50, resnet101, etc.) y tensorflow.keras.applications (ResNet50 y variantes).

Inception (GoogLeNet)




Ideal para paisajes, imágenes variadas con detalles complejos o escenarios dinámicos.

<https://paperswithcode.com/method/inception-v3>

<https://arxiv.org/abs/1409.4842>

EfficientNet



Ideal para análisis biométrico, cámaras de seguridad o cualquier tarea donde se necesite alta precisión con eficiencia computacional. Es compatible con tensorflow.keras.applications (Incluye EfficientNetB0 a EfficientNetB7) y torchvision (Implementaciones externas disponibles).



ImageNet es un extenso dataset de imágenes diseñado específicamente para entrenar y evaluar modelos de aprendizaje profundo, particularmente redes neuronales convolucionales (CNNs). Fue introducido como parte del *ImageNet Large Scale Visual Recognition Challenge* (ILSVRC), que utiliza un subconjunto del dataset completo. ImageNet contiene más de 15 millones de imágenes etiquetadas en 22,000 categorías, recopiladas de internet y anotadas por humanos mediante herramientas como Amazon Mechanical Turk.

Utiliza un conjunto de imágenes que consta de 1,000 categorías con aproximadamente:

- 1.2 millones de imágenes de entrenamiento
- 50,000 imágenes de validación
- 150,000 imágenes de prueba
- Las imágenes fueron preprocesadas para tener una resolución estándar (256x256), y sus valores se centraron en el promedio RGB de los datos de entrenamiento

Transferencia de Aprendizaje



El aprendizaje por transferencia es una técnica de aprendizaje automático que aprovecha el conocimiento adquirido al resolver una tarea para mejorar el desempeño en una tarea diferente pero relacionada. Por ejemplo, un modelo entrenado para reconocer automóviles puede utilizarse como base para identificar camiones, ya que ambos comparten características visuales similares.

Esta metodología es especialmente útil cuando se dispone de datos limitados para la nueva tarea, permitiendo que el modelo transfiera y adapte conocimientos previos, reduciendo la necesidad de entrenar desde cero.

Para profundizar en este tema, puedes consultar el artículo "[A Comprehensive Survey on Transfer Learning](https://arxiv.org/abs/1911.02685)" publicado en arXiv en noviembre de 2019. Este

<https://arxiv.org/abs/1911.02685>

CIFAR10,

conjunto para entender un CNN



En el ejercicio se usará CIFAR10, una serie de datos para practicar incluido en KERAS, consta de de cuatro conjuntos:

x_train -> Conjunto de 50 mil imágenes de 32x32 en tres tonos distintos de colores.

y_train -> Las 50 mil etiquetas indicando que es cada elemento en x_train.

x_test -> Conjunto de 10 mil imágenes de 32x32 en tres tonos distintos de colores.

y_test -> Las 10 mil etiquetas indicando que es cada elemento en x_test.



Para ver una imagen
bajo este formato
usa plt.imshow



Cada píxel cuenta con
tres dimensiones más una
por cada color RGB.

Valores de 0 a 255 por
cada capa de color.

Categorías Cifar10




airplane



automobile



bird



cat



deer



dog



frog



horse





ship



truck





Análisis de código



Permite hacer el modelo de redes neuronales

Capa de neuronales convolucionales

Reduce dimensiones

Evita overfitting con el método Dropout

Convierte tensor en vector

Dimensiones de las imágenes

Tipo de activación

```
model = Sequential()
model.add(Conv2D(32, 3, padding='same', input_shape=x_train.shape[1:], activation='relu'))
model.add(Conv2D(32, 3, activation='relu'))
model.add(MaxPooling2D())
model.add(Dropout(0.25))

model.add(Conv2D(64, 3, padding='same', activation='relu'))
model.add(Conv2D(64, 3, activation='relu'))
model.add(MaxPooling2D())
model.add(Dropout(0.25))

model.add(Flatten())
model.add(Dense(512, activation='relu'))
model.add(Dropout(0.5))
model.add(Dense(num_classes, activation='softmax'))
```




Ponte a prueba

Reto de la semana



¿Recuerdas la semana pasada que viste un dataset casas en Boston?

Es este de aquí:

<https://raw.githubusercontent.com/jbrownlee/Datasets/master/housing.csv>

Realiza lo siguiente:

- Un modelo de MLP de regresión con Keras (ya que son datos para regresión).
- Genera tres predicciones con datos aleatorios.
- Calcula el MSE y RMSE.
- Analiza los resultados.



FINALIZAMOS LA CLASE 19

¿Qué sigue?

Consultar y estudiar el repositorio de la semana 20.

- Estar pendiente de tu cuenta de Microsoft Teams.
- Asesorías grupales e individuales.
- No olvides contestar la encuesta.



Si hay temas pendientes, proyectos y entregas extemporáneas) enviar correo a staff.






Ciencia de Datos y AI

¡Nos vemos!

Excelente fin de semana

Bootcamp 

Ciencia de Datos

& AI